# Визуализация данных

В самом начале лирическое отступление. Вы, наверное, уже видели, в каких красивых блокнотах мы отдаем вам файлы. Хорошая новость - делать их несложно. Плохая новость - вам придется в таком же виде сдать нам задание #4. Поэтому крошечный тьюториал.

Чтобы поменять тип ячейки на markdown (размеченный текст) - нужно выбрать markdown для конкретной ячейке в выпадающей строке наверху файла (по умолчанию там стоит code). И все - теперь мы можем писать здесь текст, а при исполнении ячейки он станет как будто частью файла (если кликнуть на такую ячейку два раза - то ее опять можно будет редактировать).

Markdown поддерживает разметку файла - а значит, вы можете использовать теги, менять параметры текста, вставлять картинки. Мы ограничимся базовыми параметрами текста (сделайте эту ячейку редактируемой, чтобы увидеть невидимые символы).

# - Вот так делаем заголовок 1 уровня

## А так второго

А так третьего

Ну, вы поняли

Жирный текст

курсив \*

## Список:

- раз
- два
- три

На этом достаточно:)

# ▼ Вернемся к визуализации

Во-первых, кроме привычных вам графиков существует еще огромное множество всего (и некоторые вещи работают гораздо лучше привычных нам). Python умеет строить и сложные штуки. Есть несколько классных сайтов, которые помогают выбрать подходящий график для ваших данных:

https://www.data-to-viz.com/

https://datavizproject.com/

https://datavizcatalogue.com/RU/

Сегодня будем делать упражнения по мотивам вот этого блокнота

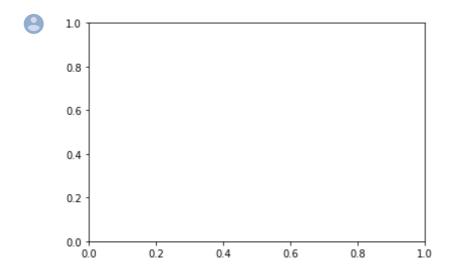
https://nbviewer.jupyter.org/github/yaph/ipython-notebooks/blob/master/movie-body-counts.ipynb

и работать с датасетом, который подсчитывает количество смертей в фильмах (меотодологию сбора данных можно посмотреть по ссылке выше).

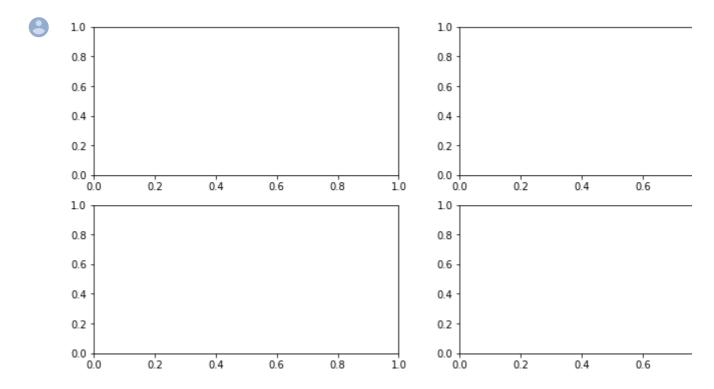
```
import os
os.chdir("C:/Users/Rogov/Desktop/Data")
os.getcwd ()
```

'C:\\Users\\Rogov\\Desktop\\Data'

fig, ax= plt.subplots(1, 1)



fig, ax = plt.subplots(2, 2, figsize=(12,6))



data = pd.read\_csv(r'populations.txt', sep='\t')

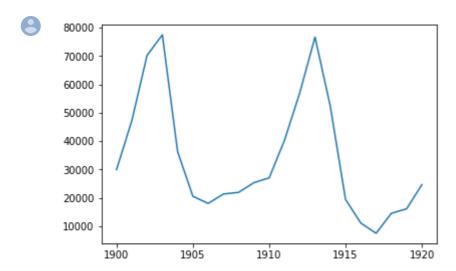
data.head()



	year	hare	lynx	carrot
0	1900	30000.0	4000.0	48300
1	1901	47200.0	6100.0	48200
2	1902	70200.0	9800.0	41500
3	1903	77400.0	35200.0	38200
4	1904	36300.0	59400.0	40600

data.year = data.year.apply(int)

fig, ax= plt.subplots(1, 1)
ax.plot(data.year, data.hare)
ax.locator\_params(integer=True)



fig, ax1= plt.subplots(2, 2, figsize=(12,8))



```
1.0
                                                                      1.0
       0.8
                                                                      0.8
ax1[0][0]
      <matplotlib.axes._subplots.AxesSubplot at 0x1c6559bd438>
                                                                      م م I
       ا دم
fig, ax1= plt.subplots(2, 2, figsize=(12,8))
for x in range(2):
     for y in range(2):
          ax1[x][y].set_xlabel('Time', fontsize = 16)
       1.0
                                                                      1.0
       0.8
                                                                      0.8
       0.6
                                                                      0.6
       0.4
                                                                      0.4
       0.2
                                                                      0.2
       0.0
                                                                      0.0
                     0.2
                               0.4
                                         0.6
                                                    0.8
                                                              1.0
                                                                                    0.2
                                                                                              0.4
                                                                                                         0.6
          0.0
                                                                         0.0
                                  Time
                                                                                                 Time
       1.0
                                                                      1.0
       0.8
                                                                      0.8
       0.6
                                                                      0.6
       0.4
                                                                      0.4
       0.2
                                                                      0.2
       0.0
                                                                       0.0
          0.0
                     0.2
                               0.4
                                         0.6
                                                    0.8
                                                               1.0
                                                                         0.0
                                                                                    0.2
                                                                                              0.4
                                                                                                         0.6
                                  Time
                                                                                                 Time
fig, ax1= plt.subplots(2, 2, figsize=(12,8))
for x in range(2):
     for y in range(2):
          ax1[x][y].set_xlabel('Time', fontsize=14)
         ax1[x][y].locator_params(integer=True)
ax1[x][y].spines['right'].set_visible(False)
ax1[x][y].spines['top'].set_visible(False)
          ax1[x][y].xaxis.set_tick_params(width=0.2)
          ax1[x][y].yaxis.set_tick_params(width=0.2)
          for axis in ['top', 'bottom', 'left', 'right']:
               ax1[x][y].spines[axis].set_linewidth(0.2)
```

ax1[0][0].plot(data.year, data.hare, color='#8c92ac', ls = ':')

ax1[0][0].set\_ylabel('Hare', fontsize=14)

```
ax1[1][1].plot(data.year, data.hare, label = 'Hares', color='#8c92ac', ls = ':'); # here
ax1[1][1].plot(data.year, data.lynx, label = 'Carrots', color='#ffa500', ls = '--'); # he
ax1[1][1].plot(data.year, data.carrot, label = 'Lynxes', color='#b06500', ls = '-'); # he
ax1[1][1].legend(loc=1, fontsize=8, frameon=False) # upper left corner
```



<matplotlib.legend.Legend at 0x1c65a897668>

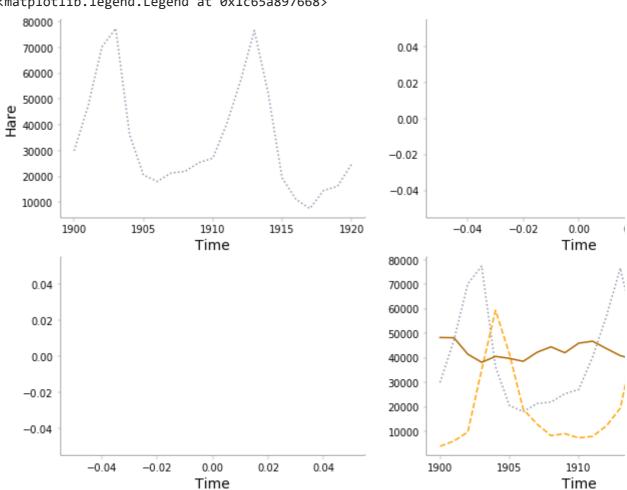


fig.savefig("my\_new\_plot.png")

os.getcwd()



'C:\\Users\\Rogov\\Desktop\\Data'

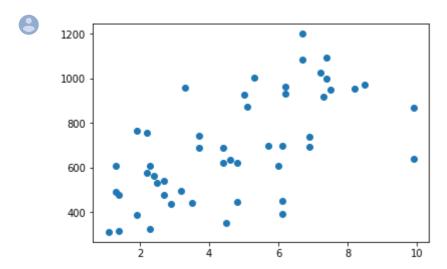
```
df = pd.read_csv('crimeRatesByState2005.tsv',header=0,sep='\t')
```

df.head()

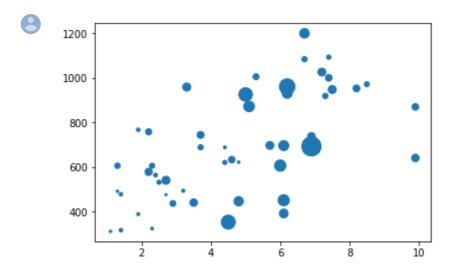




fig, ax= plt.subplots(1, 1)
sc=plt.scatter(df['murder'], df['burglary'])



fig, ax= plt.subplots(1, 1)
sc=plt.scatter(df['murder'], df['burglary'], s=df['population']/100000)



fig, ax= plt.subplots(1, 1)
sc=plt.scatter(df['murder'], df['burglary'], s=df['population']/100000, c=df['motor\_vehic
plt.colorbar(sc)

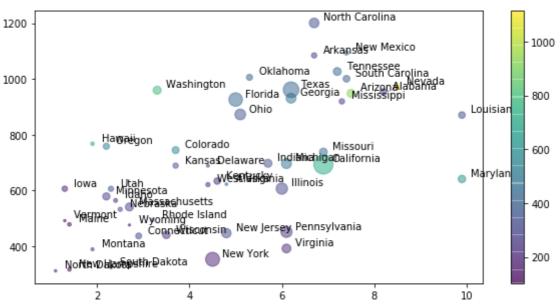


## <matplotlib.colorbar.Colorbar at 0x1c65bfc7588>

```
fig, ax = plt.subplots(1, 1, figsize=(10,5))
plt.scatter(df['murder'], df['burglary'], s=df['population']/100000, c=df['motor_vehicle
state_names = df['state']
state_data = df[df.columns[1:]]

for i in range(len(state_names)):
    ax.annotate(state_names[i], (state_data.loc[i,"murder"]+0.2, state_data.loc[i,'burglaplt.colorbar()
```

<matplotlib.colorbar.Colorbar at 0x1c65c38be80>



```
fig, ax = plt.subplots()
ax.scatter(df['murder'], df['burglary'], s = np.array(df['population']) / 30000, c = df[
ax.spines['right'].set_visible(False)
ax.spines['top'].set_visible(False)
ax.yaxis.set_ticks_position('left')
ax.xaxis.set_ticks_position('bottom')
ax.spines['left'].set_linewidth(0.5)
ax.spines['bottom'].set_linewidth(0.5)
ax.set_xlabel('Murder', fontsize = 10)
ax.set_ylabel('Bulglarly', fontsize = 10)
for i, state in enumerate(df['state']):
    ax.annotate(state, (df['murder'][i],df['burglary'][i]), fontsize = 5)
```



```
url = 'https://python-graph-gallery.com/wp-content/uploads/gapminderData.csv'
data = pd.read_csv(url)

data.head()
```

	country	year	рор	continent	lifeExp	gdpPercap
0	Afghanistan	1952	8425333.0	Asia	28.801	779.445314
1	Afghanistan	1957	9240934.0	Asia	30.332	820.853030
2	Afghanistan	1962	10267083.0	Asia	31.997	853.100710
3	Afghanistan	1967	11537966.0	Asia	34.020	836.197138
4	Afghanistan	1972	13079460.0	Asia	36.088	739.981106

my\_dpi=96

data['continent']=pd.Categorical(data['continent'])
data.head()

	country	year	рор	continent	lifeExp	gdpPercap
0	Afghanistan	1952	8425333.0	Asia	28.801	779.445314
1	Afghanistan	1957	9240934.0	Asia	30.332	820.853030
2	Afghanistan	1962	10267083.0	Asia	31.997	853.100710
3	Afghanistan	1967	11537966.0	Asia	34.020	836.197138
4	Afghanistan	1972	13079460.0	Asia	36.088	739.981106

```
tmp = data[data.year == 1962 ]
plt.scatter(tmp['gdpPercap'], tmp['lifeExp'], s=tmp['pop']/200000 , c=tmp['continent'].ca
plt.xscale('log')
plt.xlabel("GDP per Capita")
plt.ylabel("Life Expectancy")
plt.title("Year: "+str(1962) )
plt.ylim(30, 90)
plt.xlim(0,100000)
```

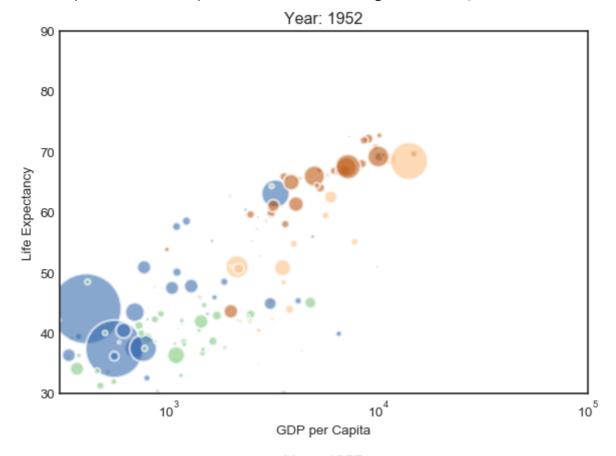


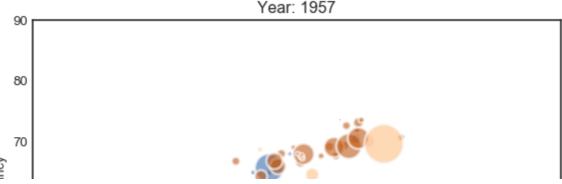
C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
 'Attempted to set non-positive xlimits for log-scale axis; '
(355.1974801060595, 100000)

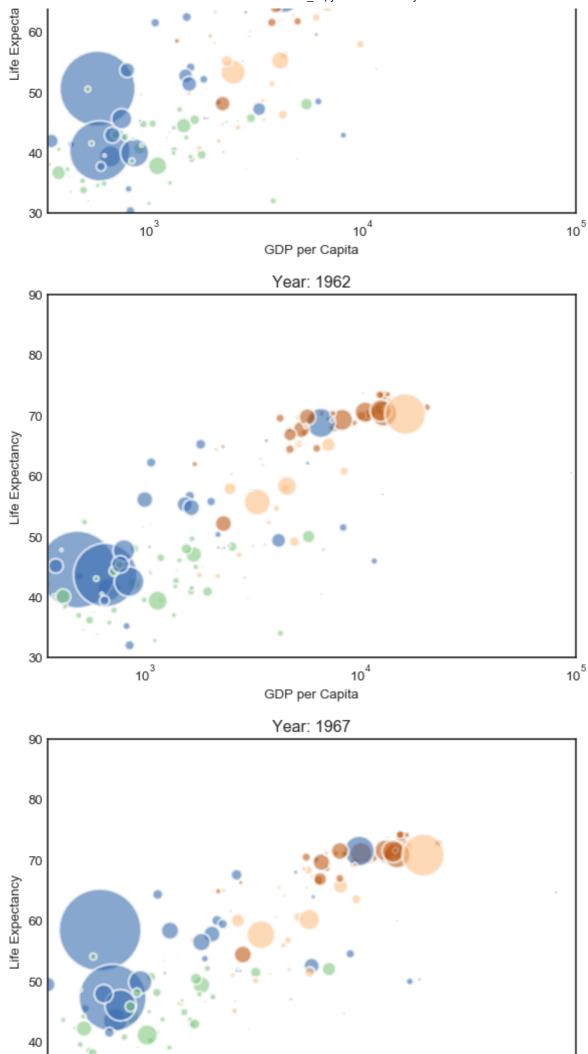
```
Year: 1962
# For each year:
for i in data.year.unique():
    # initialize a figure
    fig = plt.figure(figsize=(680/my_dpi, 480/my_dpi), dpi=my_dpi)
    # Change color with c and alpha. I map the color to the X axis value.
    tmp = data[data.year == i ]
    plt.scatter(tmp['gdpPercap'], tmp['lifeExp'], s=tmp['pop']/200000 , c=tmp['continent
    plt.xscale('log')
plt.xlabel("GDP per Capita")
    plt.ylabel("Life Expectancy")
    plt.title("Year: "+str(i) )
    plt.ylim(30, 90)
    plt.xlim(0,100000)
    # Save it
    filename='Gapminder_step'+str(i)+'.png'
    plt.savefig(filename, dpi=96)
    plt.gca()
```

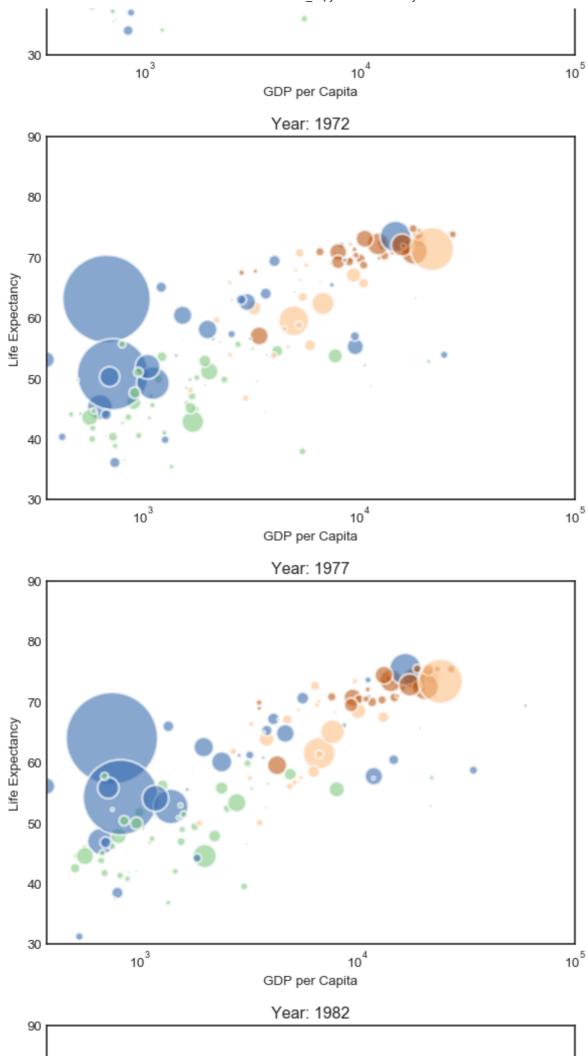


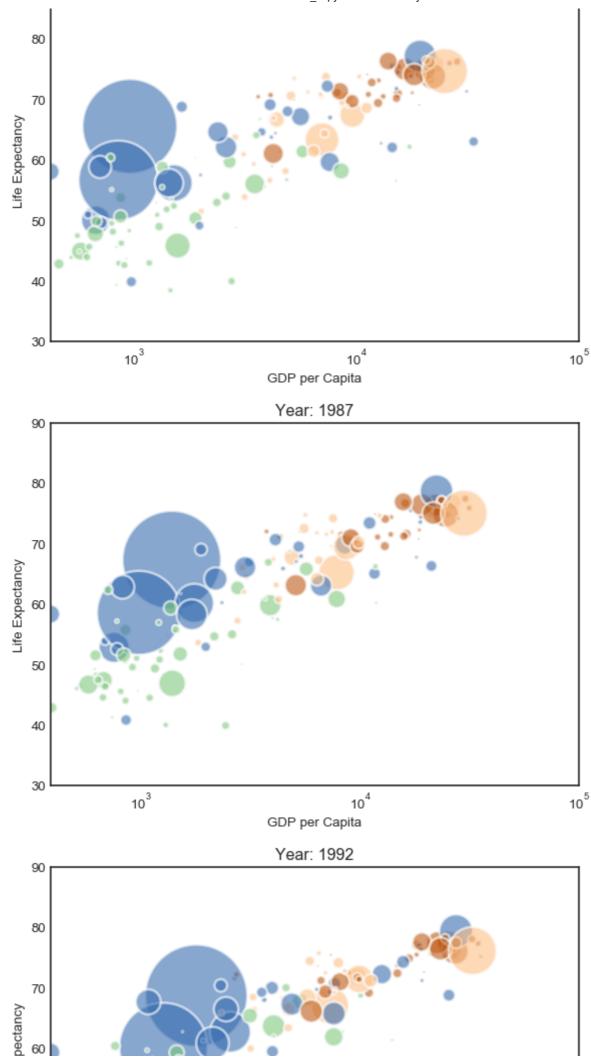
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '
- C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\axes\\_base.py:3129: UserWarr
   'Attempted to set non-positive xlimits for log-scale axis; '

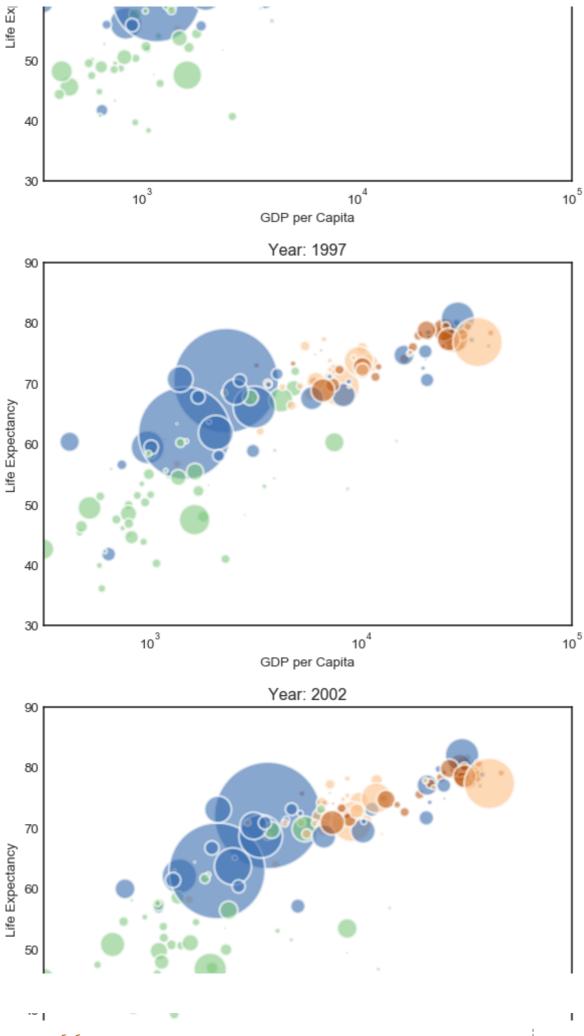












```
%matplotlib inline
import numpy as np # библиотека для работы с числами, пригодится для преобразований
import pandas as pd
import matplotlib.pyplot as plt # библиотека для визуализации
import seaborn as sns
                                 # библиотека для визуализации
         a∩ L
       File "<ipython-input-198-1699eaa8571f>", line 1
         sns.set style("whitegrid"
     SyntaxError: unexpected EOF while parsing
      SEARCH STACK OVERFLOW
      ¥ 60 I
df = pd.read_csv('filmdeathcounts.csv')
df.head()
                        Body_Count MPAA_Rating
                                                                           Genre
                                                                                     Director
           Film
                 Year
             24
           Hour
                                                                                       Michae
      0
                 2002
                                  7
                                                R Biography|Comedy|Drama|Music
                                                                                  Winterbotton
           Party
         People
             28
      1
                 2002
                                 53
                                                R
                                                              Horror|Sci-Fi|Thriller
                                                                                   Danny Boyle
           Days
           Later
```

Давайте добавим две новых переменных: счетчик фильмов (понадобится позже при группировках, для всех фильмов равен 1). И переменная, измеряющая количество трупов в минуту экранного времени:)

```
df['Film_Count'] = 1
df['Body_Count_Min'] = df['Body_Count'] / df['Length_Minutes'].astype(float)
df.head()
```

28

Directo	Genre	MPAA_Rating	Body_Count	Year	Film	•
Michae Winterbotton	Biography Comedy Drama Music	R	7	2002	24 Hour Party People	0
Danny Boyl	Horror Sci-Fi Thriller	R	53	2002	28 Days Later	1

В прошлые разы мы с вами смотрели, как группировать таблицы по паре параметров и считать описательные статистики. В pandas мы можем создавать агрегированные таблицы (суммирующие, пивотальные - вы можете знать их под этими именами). Давайте сгруппируем фильмы по году и для каждой колонки посчитаем сумму, среднее и медиану.

```
group_year = df.groupby('Year').agg([np.mean, np.median, sum])
group_year.tail()
```

3		Body_Count			Length_Minutes		IMDB_Rating			
		mean	median	sum	mean	median	sum	mean	median	sum
	Year									
	2007	85.312500	45.5	4095	114.062500	111.0	5475	6.829167	7.00	327.8
	2008	68.653846	37.0	1785	109.615385	108.5	2850	6.573077	6.65	170.9
	2009	55.000000	59.0	605	112.272727	110.0	1235	6.845455	6.60	75.3
	2010	129.750000	126.0	519	115.750000	111.0	463	7.250000	7.25	29.0
	2013	156.000000	156.0	156	119.000000	119.0	119	6.500000	6.50	6.5

df\_bc.head()

mean value median val
-----------------------

Year		
1949	4.0	4.0
1954	57.5	57.5
1957	67.0	67.0
1959	7.0	7.0
1960	55.0	55.0

df\_bc\_min.head()



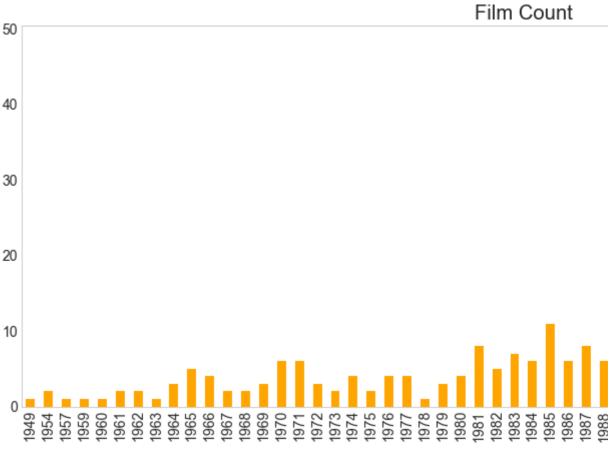
mean va.	Lue	median	value

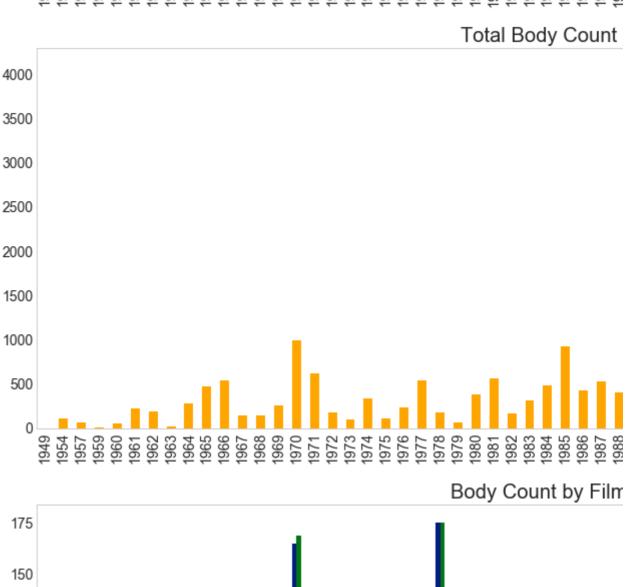
Year		
1949	0.038462	0.038462
1954	0.425822	0.425822
1957	0.761364	0.761364
1959	0.088608	0.088608
1960	0.429688	0.429688

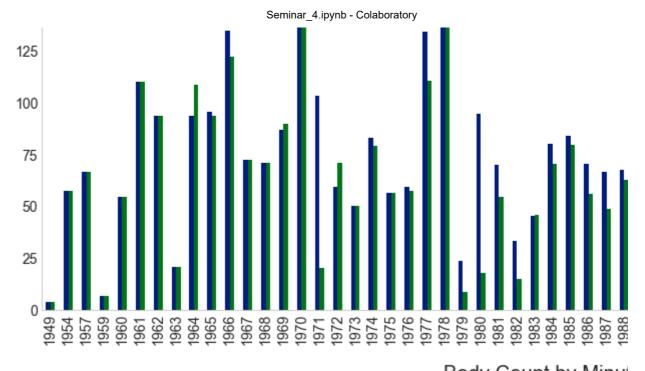
plt.style.available

```
['bmh',
       'classic',
      'dark_background',
      'fast',
      'fivethirtyeight',
      'ggplot',
      'grayscale',
      'seaborn-bright',
      'seaborn-colorblind',
      'seaborn-dark-palette',
      'seaborn-dark',
      'seaborn-darkgrid',
      'seaborn-deep',
      'seaborn-muted'
      'seaborn-notebook',
      'seaborn-paper',
      'seaborn-pastel'
      'seaborn-poster',
      'seaborn-talk',
      'seaborn-ticks',
      'seaborn-white',
      'seaborn-whitegrid',
      'seaborn',
      'Solarize_Light2',
      'tableau-colorblind10',
      '_classic_test']
# plt.style.use('seaborn-dark-palette')
sns.set_style("whitegrid")
fig, axes = plt.subplots(nrows=4, ncols=1, figsize=(16, 30))
group_year['Film_Count']['sum'].plot(kind='bar', ax=axes[0], color = '#ffa500')
axes[0].set_title('Film Count')
group_year['Body_Count']['sum'].plot(kind='bar', ax=axes[1], color = '#ffa500')
axes[1].set_title('Total Body Count')
df_bc.plot(kind='bar', ax=axes[2])
axes[2].set_title('Body Count by Film')
df bc min.plot(kind='bar', ax=axes[3])
axes[3].set_title('Body Count by Minute')
for i in range(4):
    axes[i].set_xlabel('', visible=False)
    axes[i].grid(b = False)
```









# Body Count by Minut 1.4 mean\_value 1.2 1.0 0.8 0.6

df.head()

Directo	Genre	MPAA_Rating	Body_Count	Year	Film	)	•
Michae Winterbotton	Biography Comedy Drama Music	R	7	2002	24 Hour Party People	0	
Danny Boyle	Horror Sci-Fi Thriller	R	53	2002	28 1 Days Later	1	
					28		

df\_film = df.set\_index('Film')
df\_film.head()



axes[1].yaxis.set\_ticks\_position('right')

axes[i].set\_ylabel('', visible=False)

Genre

Director L

Film

24 Michael Hour 2002 7 R Biography|Comedy|Drama|Music Winterbottom **Party** 

```
df_film.sort_values(by=['Body_Count'])['Body_Count'].tail(10)
```

Year Body\_Count MPAA\_Rating

```
Film
     King Arthur
                                                       378
     Windtalkers
                                                       389
     Lord of the Rings: Two Towers
                                                       468
     A Fistful of Dynamite
                                                       471
     The Last Samurai
                                                       558
     Troy
                                                       572
     Tae Guk Gi: The Brotherhood of War
                                                       590
     300
                                                       600
     Kingdom of Heaven
                                                       610
     Lord of the Rings: Return of the King
                                                       836
     Name: Body_Count, dtype: int64
fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(10, 8))
bc = df_film.sort_values(by=['Body_Count'])['Body_Count'].tail(10)
bc.plot(kind='barh', ax=axes[0])
axes[0].set_title('Total Body Count')
bc min = df film.sort values(by=['Body Count Min'])['Body Count Min'].tail(10)
bc_min.plot(kind='barh', ax=axes[1])
axes[1].set_title('Body Count per Minute')
```

for i in range(2):

axes[i].grid('False')

C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\cbook\deprecation.py:107: Ma warnings.warn(message, mplDeprecation, stacklevel=1)

C:\Users\rogov\Anaconda3\lib\site-packages\matplotlib\cbook\deprecation.py:107: Ma warnings.warn(message, mplDeprecation, stacklevel=1)



# Most violent directors

```
df[df['Director'].apply(lambda x: -1 != x.find('|'))].head()
```

```
Film
                             Body Count MPAA Rating
                                                                             Genre
                                                                                         Directo
                      Year
            Aliens vs.
                                                                                             Co
      26
            Predator.
                      2007
                                                         Action|Horror|Sci-Fi|Thriller
                                       5
                                                                                      Strause|Gre
            Requiem
                                                                                           Strau
           Aqua Teen
              Hunger
               Force
      38
               Colon
                      2007
                                      67
                                                     R Animation|Action|Adventure Maiellaro|Da
               Movie
                                                                                             Wil
             Eilm for
def expand_col(df_src, col, sep='|'):
    di = \{\}
    idx = 0
    for i in df_src.iterrows():
        d = i[1]
        names = d[col].split(sep)
        for name in names:
            # operate on a copy to not overwrite previous director names
            c = d.copy()
            c[col] = name
            di[idx] = c
            idx += 1
    df new = pd.DataFrame(di).transpose()
    # these two columns are not recognized as numeric
    df_new['Body_Count'] = df_new['Body_Count'].astype(float)
    df_new['Body_Count_Min'] = df_new['Body_Count_Min'].astype(float)
    return df_new
bc_sum = df_dir.groupby('Director').sum().sort_values(by=['Body_Count']).tail(10)
bc sum
```



Μŧ

## Body\_Count\_Min

## **Director**

Je-kyu Kang	1770.0	12.642857
Uwe Boll	1818.0	16.766390
Steven Spielberg	1824.0	12.095150
Antoine Fuqua	2015.0	16.781665
Wolfgang Petersen	2095.0	15.862454
Zack Snyder	3155.0	27.126865
Ridley Scott	3562 N	<i>21</i> 762 <i>1</i> 00

bc\_mean = df\_dir.groupby('Director').agg(np.mean).sort\_values(by=['Body\_Count\_Min']).tail
bc\_mean



Body\_Count Body\_Count\_Min

## Director

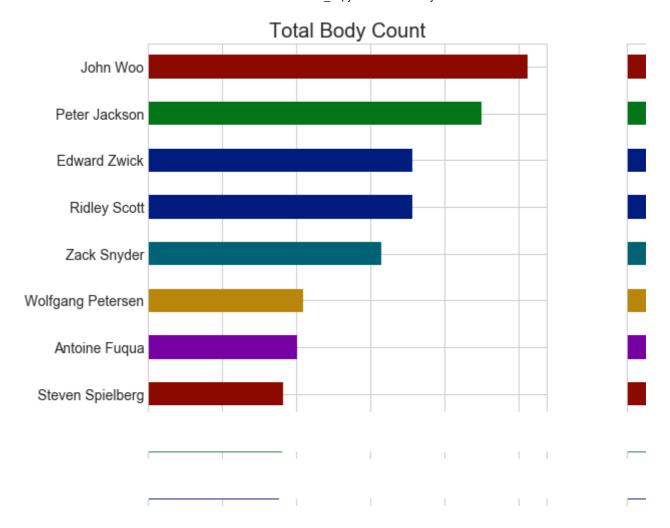
Randall Wallace	305.000000	2.210145
King Hu	213.000000	2.242105
Sylvester Stallone	225.000000	2.327828
Kevin Munroe	206.000000	2.367816
Zack Snyder	286.818182	2.466079
<b>Edward Zwick</b>	356.700000	2.476085
Katja von Garnier	256.000000	2.612245
Simon Hunter	310.000000	2.792793
Samuel Fuller	338.000000	2.991150
Je-kyu Kang	590.000000	4.214286

```
fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(14, 8))
bc_sum['Body_Count'].plot(kind='barh', ax=axes[0])
axes[0].set_title('Total Body Count')

bc_mean['Body_Count_Min'].plot(kind='barh', ax=axes[1])
axes[1].set_title('Body Count per Minute')
axes[1].yaxis.set_ticks_position('right')

for i in range(2):
    axes[i].set_ylabel('', visible=False)
```



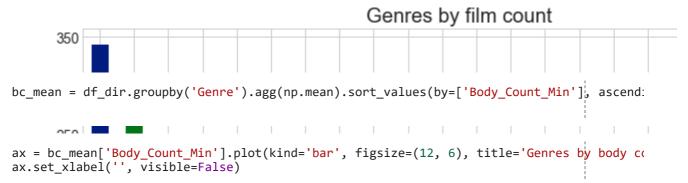


# by genre

df\_dir['Genre'].value\_counts().plot(kind='bar', figsize=(12, 6), title='Genres by film continue.

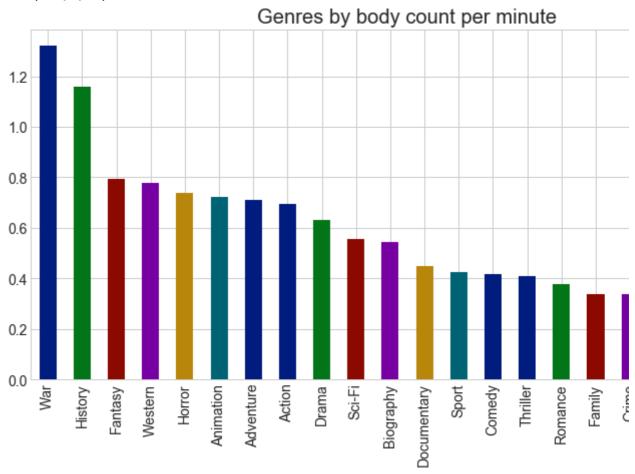


<matplotlib.axes.\_subplots.AxesSubplot at 0x1c65e767668>



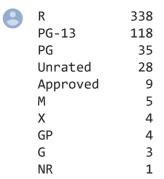
8

Text(0.5,0,'')



# Rankings

df['MPAA\_Rating'].value\_counts()



Name: MPAA\_Rating, dtype: int64

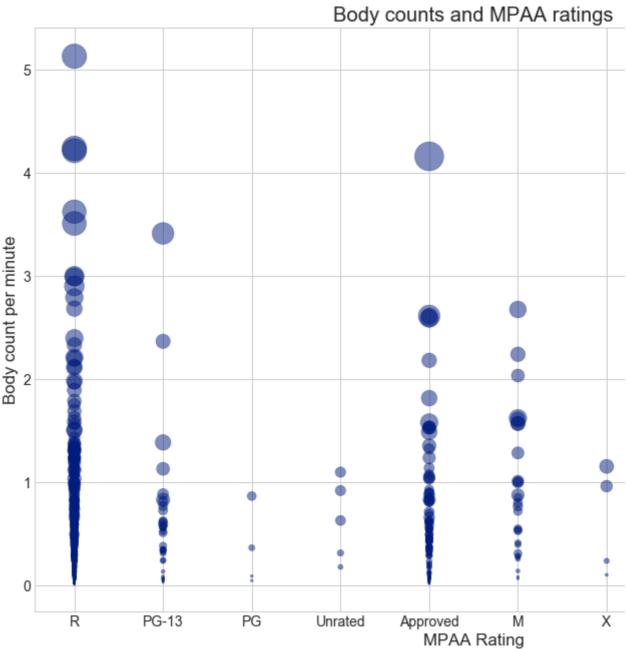
df['Body\_Count\_Min'].max()



5.128205128205129

```
fig, ax = plt.subplots(figsize=(14, 10))
ax.scatter(df['MPAA_Rating'], df['Body_Count_Min'], s=df['Body_Count'], alpha=.5)
ax.set_title('Body counts and MPAA ratings')
ax.set_xlabel('MPAA Rating')
ax.set_xticks(rating_index)
ax.set_xticklabels(rating_names)
ax.set_ylabel('Body count per minute')
```

Text(0,0.5,'Body count per minute')



bc\_top.reset\_index()



Genre

```
Lord of
```

IIC COITE

```
bc_top = df.sort_values('Body_Count', ascending=False)[:3].reset_index()
annotations = []
for r in range(len(bc_top)):
    annotations.append([bc_top['Film'][r], bc_top['IMDB_Rating'][r], bc_top['Body_Count_N
annotations
     [['Lord of the Rings: Return of the King', 8.9, 4.159203980099503],
       ['Kingdom of Heaven', 7.1, 4.23611111111111],
       ['300', 7.7, 5.128205128205129]]
fig, ax = plt.subplots(figsize=(14, 10))
ax.scatter(df['IMDB_Rating'], df['Body_Count_Min'], s=df['Body_Count'], alpha=.5)
ax.set_title('Body count and IMDB ratings')
ax.set_xlabel('IMDB Rating')
ax.set_ylabel('Body count per minute')
for annotation, x, y in annotations:
    plt.annotate(
         annotation,
         xy=(x, y),
         xytext=(0, 30),
         textcoords='offset points',
         ha='center',
         va='bottom'
         size=12.5,
         bbox=dict(boxstyle='round,pad=0.5', fc='yellow', alpha=0.5),
         arrowprops=dict(arrowstyle='-'))
```

```
NameError
                                          Traceback (most recent call last)
<ipython-input-300-62f93a425715> in <module>()
                arrowprops=dict(arrowstyle='-'))
---> 19 plt.annotate(chartinfo, xy=(0, -1.12), xycoords='axes fraction')
```

NameError: name 'chartinfo' is not defined

